

Интеллектуальная система обработки информации при мониторинге рельсовых путей

С. П. Орлов¹, Р. В. Гири², А. В. Пилецкая³

Самарский государственный технический университет

¹orlovsp1946@gmail.com, ²romangirin@gmail.com, ³piletskaya.tonya@gmail.com

Аннотация. В докладе рассматривается задача оперативной обработки визуальной информации о состоянии рельсового пути железной дороги. Описана структура информационной системы с четырьмя видеокамерами, расположенными на подвижном вагоне-дефектоскопе, и автоматизированным рабочим местом для статистической предобработки данных. Показано, что основная проблема заключается в распознавании дефектных состояний элементов инфраструктуры железнодорожного рельсового пути. Предложена глубокая нейронная сеть для классификации технических состояний креплений рельсового пути. Описана процедура подготовки обучающей и тестовой выборки. Предложена методика синтеза модельных состояний рельсовых креплений наиболее распространенных типов. Приведены результаты экспериментальных исследований интеллектуальной системы обработки информации с нейронной сетью, работающей в реальном времени при высоких скоростях прохождения вагона-дефектоскопа.

Ключевые слова: информационные системы; техническая диагностика; железнодорожный путь; неразрушающий контроль рельсовых креплений; искусственная нейронная сеть; глубокое обучение

I. ВВЕДЕНИЕ

Организация высокоскоростных железнодорожных магистралей и управление движением скоростных поездов включают в себя задачу постоянного контроля состояния рельсового пути. При этом исправность креплений рельсов – один из важнейших факторов, влияющих на безопасность и надежность [1]. Для контроля железнодорожного пути в настоящее время, кроме визуального осмотра путевыми бригадами, широко используют автоматизированные системы, установленные на передвижных вагонах-дефектоскопах [2–4].

Существует проблема оперативного анализа получаемых данных, которые операторы не могут обработать в реальном времени. Например, на одном километре железнодорожного пути может находиться больше 8 тысяч рельсовых креплений. Такой большой объем данных делает невозможным ручную проверку изображений и обнаружение дефектов рельсовых креплений. Другой аспект проблемы связан с современной тенденцией установки автономной аппаратуры контроля рельсового пути на вагоны

регулярных скоростных поездов для постоянного мониторинга.

Решение данной задачи предлагается выполнить с использованием интеллектуальных методов обработки больших массивов информации. Известны методы и информационные системы для визуальной диагностики технических состояний различных объектов на основе интеллектуальных технологий [5–8]. В тоже время авторы настоящего доклада в течение ряда лет развивают подход к использованию искусственных нейронных сетей и глубокого обучения для обработки диагностической информации в реальном времени при управлении сложными системами, в том числе транспортными [9–11].


II. ОБЩАЯ СТРУКТУРА ИНТЕЛЛЕКТУАЛЬНОЙ ИНФОРМАЦИОННОЙ СИСТЕМЫ

Множество типов рельсовых креплений, классифицируемых с помощью описываемой информационной системы, приведено в табл. I.

Примеры работоспособного и дефектного крепления КБ показаны на рис. 1.

ТАБЛИЦА I ТИПЫ КОНТРОЛИРУЕМЫХ РЕЛЬСОВЫХ СКРЕПЛЕНИЙ

Номер типа	Тип крепления	Виды дефектов крепления
1	ДО2	Трещина в подкладке; разворот подкладки; ДО2 без костыля; ДО2 с наддернутым костылем
2	ДО3	Трещина в подкладке; разворот подкладки; ДО3 без костыля; ДО3 с наддернутым костылем
3	КБ	Трещина в подкладке; разворот подкладки; без болта; без гайки; без клеммы; с изломом клеммы
4	КБОП 105	Трещина в подкладке; разворот подкладки; без болта; без гайки; без клеммы; с изломом клеммы
5	ЖБР	Трещина в подкладке; разворот подкладки; без болта; без гайки; без клеммы; с изломом клеммы
6	АРС	Трещина в подкладке; разворот подкладки; без клеммы; с изломом клеммы



а) б)

Рис. 1. Рельсовое крепление типа КБ для железобетонных шпал
а) без дефектов, б) отсутствие болта

В общем виде задача формулируется следующим образом. Число типов контролируемых креплений равно N . Множество всех изображений креплений типа n обозначено, как D^n , $n = \overline{1, N}$.

Тогда подмножество изображений креплений типа n с техническим состоянием k , есть D_k^n , $k = \overline{1, K_n}$, где K_n – число контролируемых видов состояний для n -го типа креплений.

При этом индекс $k = 0$ соответствует исправным креплениям и D_0^n – множество всех исправных креплений. Остальные значения k соответствуют различным видам дефектов в креплениях. Множество изображений всех креплений одного типа

$$D^n = \{d_{kj}^n\}, j = \overline{1, J_{nk}},$$

где J_{nk} – число изображений одного вида состояния крепления; d_{kj}^n – одно фотоизображение крепления.

Структура интеллектуальной информационной системы представлена на рис. 2. Информационная система установлена в мобильном вагоне-дефектоскопе и обеспечивает контроль креплений в реальном времени при проезде по участку железнодорожного пути. На днище вагона установлены четыре видеокамеры ВК 1 – ВК 4, непрерывно снимающие изображения рельсов и железнодорожного полотна. Автоматизированное рабочее место АРМ производит предварительную обработку видеопотока. При этом на кадрах выделяются области со креплениями, которые затем формируются в пакеты данных, поступающих на диагностическую нейронную сеть. Результаты классификации передаются в систему поддержки принятия решений (СППР) оператором. База данных БД используется для хранения данных и результатов мониторинга.



Рис. 2. Структура интеллектуальной информационной системы мониторинга рельсового пути

Информация о состоянии рельсового пути передается в Центр диагностики пути железной дороги для управления и оперативного информирования диспетчерских служб при аварийных ситуациях.

III. АРХИТЕКТУРА ГЛУБОКОЙ КОНВОЛЮЦИОННОЙ НЕЙРОННОЙ СЕТИ

В качестве нейронной сети использован вариант конволюционной сети VGG [12]. Глубокая нейронная сеть представляет собой конволюционную сеть, реализованную с помощью библиотеки Keras [13–14]. Структура сети приведена в табл. II.

Нейронная сеть имеет входное поле восприятия 3×3 пикселей при размере входного изображения 248×248 пикселей. В ее состав входят 6 конволюционных слоев и 5 слоев макс-пулинга. Выходной слой имеет семь нейронов, выходы которых показывают значение вероятностей отнесения анализируемого крепления к тому или иному классу табл. I. Класс F содержит нераспознанные крепления. Использование многослойной конволюционной сети обеспечивает извлечение характерных черт рельсовых креплений, и повышение уровня абстракции от слоя к слою [15].

ТАБЛИЦА II СТРУКТУРА ГЛУБОКОЙ КОНВОЛЮЦИОННОЙ СЕТИ ДЛЯ КЛАССИФИКАЦИИ РЕЛЬСОВЫХ СКРЕПЛЕНИЙ

Тип слоя	Характеристики слоя	Число параметров (весов)
Conv2d 1	248, 248, 32	320
Batch Normalizatuin 1	248, 248, 32	128
Conv2d 2	246, 246, 64	18496
Max pooling2d 1	123, 123, 64	0
Conv2d 3	121, 121, 128	73856
Batch Normalizatuin 2	121, 121, 128	512
Max pooling2d 2	60, 60, 128	0
Conv2d 4	58, 58, 128	147584
Max pooling2d 3	29, 29, 128	0
Conv2d 5	27, 27, 256	295168
Batch Normalizatuin 3	27, 27, 256	1024
Max pooling2d 4	13, 13, 256	0
Conv2d 6	11, 11, 256	590080
Max pooling2d 5	5, 5, 256	0
Flatten 1	6400	0
Dense 1	1024	6554624
Batch Normalizatuin 4	1024	4096
Dense 2	7	7175
Число параметров в сети		7 693 063

IV. ПОДГОТОВКА ОБУЧАЮЩЕЙ И ТЕСТОВОЙ ВЫБОРКИ

Подготовленная в АРМ выборка исправных креплений для одного из участков пути имеет вид:

- ДО2 – 966 изображений;
- ДО3 – 2053 изображения;
- КБ – 9451 изображение;
- КБОП 105 – 1025 изображений;
- ЖБР – 2249 изображений;
- АРС – 9646 изображений.

В известных работах по машинному обучению отмечается проблема недостаточного количества дефектных элементов для уверенной классификации [8, 16]. Для повышения точности разработанной нейронной сети была собрана обучающая выборка (датасет), репрезентативность которой была увеличена с использованием двух различных техник дополнения датасета: а) техника Synthetic Minority Over-Sampling Technique (SMOTE) [17], б) аффинные преобразования.

В результате получено расширенное множество синтезированных изображений креплений, что позволило выполнить балансировку датасета по типам креплений. На множестве исходных изображений, в общем количестве 25390, была выполнена балансировка с помощью техники SMOTE с получением итогового количества изображений, равном 57876. Полученная выборка из 57876 изображений разделена на обучающую и тестовую выборки в соотношении 80% к 20%. Число изображений в обучающей и тестовой выборках составило 46300 и 11575, соответственно. Обучающая выборка в количестве 46300 изображений была дополнена с помощью аффинных преобразований. В результате было получено итоговое

количество изображений, равное 64821, на которых была обучена нейронная сеть.

После дополнения обучающей выборки с помощью аффинных преобразований вместе с тестовой выборкой общее число изображений, используемых в экспериментах на данном этапе, составило 89800 изображений. На рис. 3 представлена диаграмма сбалансированных компонентов обучающего датасета.

V. ЭКСПЕРИМЕНТАЛЬНЫЕ РЕЗУЛЬТАТЫ

В процессе обучения разработанной нейронной сети выполнена проверка на тестовой выборке. При анализе точности распознавания отдельных типов креплений использовалась матрица несоответствий (Confusion matrix) [18]. Это позволяет получить более детальное описание точности классификации и ошибок первого и второго рода для каждого типа контролируемого рельсового крепления. Результаты тестирования приведены в табл. III. Класс F включает все объекты, не относящиеся к креплениям из табл. I. Это крепления других типов, некачественные изображения железнодорожного полотна и т.п. В каждой строке матрицы все элементы, кроме диагонального, определяют количество ошибок первого рода. Ошибки второго рода могут быть оценены по значениям в элементах столбцов матрицы несоответствий.

Общая точность классификации по всем креплениям составила 97,2 %.

ТАБЛИЦА III МАТРИЦА НЕТОЧНОСТЕЙ ПРИ ТЕСТИРОВАНИИ ОБУЧЕННОЙ ДИАГНОСТИЧЕСКОЙ НЕЙРОННОЙ СЕТИ (%)

	ДО2	ДО3	КБ	КБ ОП 105	ЖБР	АРС	F
ДО2	99,74	0,91	0,23	0,43	0,60	0	0,09
ДО3	2,63	95,81	0,05	0,1	0,68	0	0,73
КБ	0,13	0,18	96,9	1,0	0	0	1,79
КБ ОП 105	0	0	0,75	96,99	0,08	0,23	1,95
ЖБР	0,16	0,05	0	0,13	98,77	0,42	0,47
АРС	0,29	0,39	0,55	0,33	0,21	97,6	0,63
F	1,94	0,58	1,23	0,18	0,24	0,03	95,8

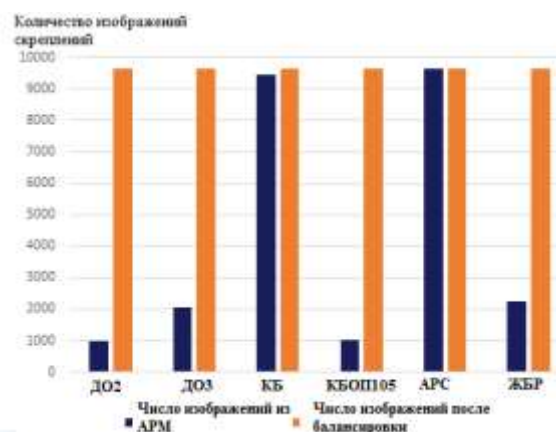


Рис. 3. Диаграммы экземпляров датасета до и после балансировки

При работе нейронной сети в вагоне-дефектоскопе на участках железных дорог общей длиной 43 км с различными типами рельсовых скреплений получена точность не менее 89%. Различие с тестовыми данными объясняется погрешностями, вносимыми средствами АРМ (рис. 2), а также динамическими погрешностями при высоких скоростях передвижения вагона-дефектоскопа.

VI. ЗАКЛЮЧЕНИЕ

В результате исследований предложена методика построения диагностической искусственной нейронной сети для мониторинга и выявления дефектов рельсовых скреплений. Для решения проблемы недостаточного количества дефектных объектов предложено синтезировать новые изображения для дополнения обучающего датасета. Перспективным направлением дальнейших исследований является разработка диагностической системы на базе специализированных векторно-матричных и нейроморфных процессоров [19, 20] для увеличения быстродействия.

VII. СПИСОК ЛИТЕРАТУРЫ

- [1] Концепция развития систем диагностики и мониторинга объектов путевого хозяйства на период до 2025 года. Режим доступа: <https://rulaws.ru/acts/Rasporyazhenie-OAO-RZHD-ot-27.04.2016-N-777r/> (дата обращения 29.07.2019)
- [2] ИНФОТРАНС. Компьютеризированный вагон-лаборатория для контроля контактной сети, автоматики и связи КВЛ-АРКС (КВЛ-Э.2, КВЛ-Ш). Режим доступа: <http://www.infotrans-logistic.ru/page.htm?title=КВЛ-АРКС> (дата обращения: 19.05.2019)
- [3] Hao Feng, Zhigou Jiang, Fengying Xie, Ping Yang, Jun Shi, Long Chen. Automatic fastener classification and defect detection in vision-based railway inspection systems//IEEE Transactions on Instrumentation and Measurement. 2014. V. 63(4). P.877-888. DOI 10.1109/TIM.2013.2283741
- [4] Karakose M., Yaman O., Akin E., Baygin M., Murat K. A new computer vision based method for rail track detection and fault diagnosis in railways//International Journal of Mechanical Engineering and Robotics Research. 2017. V. 6. No. 1. P. 22-27. DOI 10.18178/ijmerr.6.1.22-27
- [5] Селиванова З.М. Интеллектуализация информационно-измерительных систем неразрушающего контроля теплофизических свойств твердых материалов. М.: «Машиностроение-1», 2006. 184 с.
- [6] Башмаков А.И., Башмаков И.А. Интеллектуальные информационные технологии. М.: Изд-во МГТУ им. Н.Э. Баумана, 2005. 304 с.
- [7] Orlov S.P., Vasilchenko A.N. Intelligent measuring system for testing and failure analysis of electronic devices//Proceedings of the 2016 XIX IEEE International Conference on Soft Computing and Measurements. 2016. V.1. P.401-403. DOI: 10.1109/SCM.2016.7519793
- [8] Faghieh-Roohi S., Hajizadeh S., Nunez A., Babuska R., De Schutter B. Deep convolutional neural networks for detection of rail surface defects//Proceedings of the 2016 International Joint Conference on Neural Networks (IJCNN), Vancouver, BC, Canada. 2016. P. 2584-2589. DOI: 10.1109/SCM.2016.7519793
- [9] Гирин Р.В., Орлов С.П. Нейросетевой программный анализатор для контроля элементов железнодорожного пути//Вестник СамГУПС. 2019. № 1. С. 110-117.
- [10] Orlov S.P., Girin R.V., Uyutova O.Yu. Artificial neural network for technical diagnostics of control systems by thermography//Proceedings of 2018 International Conference on Industrial Engineering, Applications and Manufacturing (ICIEAM). 2019. P. 1 – 4. DOI: 10.1109/ICIEAM.2018.8728586
- [11] Орлов С.П., Гирин Р.В., Уютова О.Ю. Интеллектуализация информационно-измерительных систем контроля и диагностирования на основе нейросетевых технологий//Мягкие измерения и вычисления. 2018. № 4. С.4-12.
- [12] VGG. Режим доступа: <https://www.robots.ox.ac.uk/~vgg/publications/2015/Simonyan15/> (дата обращения 12.05.2019)
- [13] Шолле Ф. Глубокое обучение на Python. СПб.: Питер, 2018. 400 с.
- [14] Keras: The Python deep learning library. Режим доступа: <https://keras.io/applications/> (дата обращения: 25.07.2019)
- [15] Krizhevsky A., Sutskever I., Hinton G. ImageNet classification with deep convolutional neural networks//NIPS'12 Proceedings of the 25th International Conference on Neural Information Processing Systems. 2012. V. 1. P. 1097-1105.
- [16] Gibert X., Patel V.M., Chellappa R. Deep multi-task learning for railway track inspection//IEEE Transactions on Intelligent Transportation Systems. 2017. V. 18. I. 1. P. 153-164.
- [17] Chawla N.V., Bower K.W., Hall L.O., Kegelmeyer W.P. SMOTE. Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 2002, vol. 16, pp. 321–357.
- [18] Kuhn M., Johnson K. Applied predictive modeling. NY.: Springer, 2013. 615 p.
- [19] Neuromorphic computing. Режим доступа: <https://www.intel.com/content/www/us/en/research/neuromorphic-computing.html> (дата обращения: 15.05.2019)
- [20] Deep learning inference possible in embedded systems thanks to TrueNorth. Режим доступа: <https://www.ibm.com/blogs/research/2016/09/deep-learning-possible-embedded-systems-thanks-truenorth/> (дата обращения 29.07.2019)