

Архитектура глобально рекуррентных нейронных моделей динамических систем

Е. Б. Соловьева¹, А. Н. Агеев²

Санкт-Петербургский государственный электротехнический университет

«ЛЭТИ» им. В.И. Ульянова (Ленина)

¹selenab@hotmail.ru, ²alexandr1997ag@mail.ru

Аннотация. Рассмотрены структуры глобально рекуррентных нейронных сетей, применяемых в качестве математических моделей нелинейных динамических систем. Моделирование выполняется в рамках принципа «черного ящика», когда нелинейное устройство описывается оператором, устанавливающим однозначное соответствие между множеством входных и выходных сигналов. Нейронные сети выступают как аппроксиматоры нелинейных операторов. Представлены структуры и описаны свойства глобально рекуррентных нейронных сетей с разным расположением обратных связей.

Ключевые слова: математическая модель; нелинейный оператор; динамическая система; рекуррентная нейронная сеть

I. ВВЕДЕНИЕ

В последние десятилетия нейронные сети находят применение во многих областях техники, где они используются для решения многочисленных задач, включая идентификацию, моделирование и синтез нелинейных динамических систем. Указанные задачи можно сформулировать в аппроксимационной постановке, когда требуется построить математическую модель нелинейного оператора, однозначно отображающего множество входных сигналов во множество выходных сигналов динамической системы [1], [2]. Нейронные сети привлекательны в ситуации, когда полиномиальные модели нелинейного оператора с ростом степени дают медленно уменьшающуюся погрешность аппроксимации оператора.

Рекуррентные нейронные сети (recurrent neural network, RNN) считаются развитием однонаправленных перцептронных сетей (или сетей прямого распространения, feed-forward neural networks) путем добавления обратных связей [1], [2]. В каждом контуре (петле) обратной связи присутствует элемент задержки, благодаря которому поток сигналов может считаться однонаправленным (выходной сигнал предыдущего временного цикла рассматривается как априори заданный, который просто увеличивает размерность входного вектора). С помощью обратной связи можно накапливать информацию и использовать ее при обработке сигналов.

Рекуррентная нейронная сеть может содержать меньшее число параметров по сравнению с многослойной перцептронной сетью, выполняющей ту же задачу. Однако

алгоритм обучения RNN, адаптирующий значения синаптических весов, более сложен вследствие зависимости сигналов в текущий момент времени от их значений в предыдущие моменты и соответственно ввиду более громоздкой формулы для расчета вектора градиента. Кроме того, из-за наличия обратных связей необходимо исследовать вопрос устойчивости сети [1].

Тем не менее, за последние годы достигнут значительный успех в применении рекуррентных нейронных сетей для решения задач моделирования, синтеза, распознавания, предсказания, классификации, управления и т. д. [2]–[5].

В зависимости от расположения обратных связей, влияющих на организацию взаимодействия нейронов, можно выделить два класса RNN:

- Глобально рекуррентные сети, в которых допускаются обратные связи между нейронами одного слоя или разных слоев;
- Локально рекуррентные сети, содержащие обратные связи внутри нейронов. Обратные связи между нейронами одного слоя или разных слоев отсутствуют.

Рассмотрим структуры, свойства и области применения глобально рекуррентных нейронных сетей.

II. ГЛОБАЛЬНО РЕКУРРЕНТНЫЕ НЕЙРОННЫЕ СЕТИ

A. Полносвязная рекуррентная сеть

Наиболее общая структура глобальной рекуррентной нейронной сети, в которой присутствуют любые связи между нейронами, называется полносвязной структурой или рекуррентной сетью реального времени (real time recurrent network, RTRN), поскольку она предназначена для обработки сигналов в реальном времени [1], [2].

Структура RTRN показана на рис. 1. Обратная связь RTRN включает задержанные выходные сигналы сети; p , N , M – количество внешних входов, выводов обратной связи и выходных сигналов сети соответственно.

RTRN может моделировать широкий класс динамических систем [1], [2]. Однако, структура RTRN оказывается слишком сложной для конструктивного применения.




Рис. 1. Структура RTRN

В. Частично рекуррентные сети

Архитектура частично рекуррентных сетей основана на многослойном персептроне, включающем дополнительный слой, называемый контекстным слоем. Сигналы этого слоя описывают внутреннее состояние сети.

Обратные связи частично рекуррентных сетей более структурированы по сравнению с полносвязными сетями, поэтому они быстрее обучаются и имеют меньшее число проблем потери устойчивости. Тем не менее, число состояний сети по-прежнему зависит от количества скрытых или выходных нейронов, что существенно ограничивает гибкость сети.

Среди частично рекуррентных сетей выделим следующие наиболее популярные структуры [1], [2]:

- сеть Элмана (Elman network);
- сеть Джордана (Jordan network);
- рекуррентная многослойная персептронная сеть (recurrent multi-layer perceptron network, RMLPN).

Сеть Элмана часто применяется в системах управления движущимися объектами для обнаружения изменений характеристик сигналов [2].

Структура сети Элмана показана на рис. 2. В структуре присутствуют частичная рекуррентность в виде обратной связи в скрытом слое и однонаправленная связь между скрытым и выходным слоями.

Сеть Джордана решает тот же класс задач, что и сеть Элмана, однако обладает лучшими аппроксимирующими и предсказывающими свойствами благодаря более

«глубокой» памяти и дополнительному слою нелинейных функций активации.

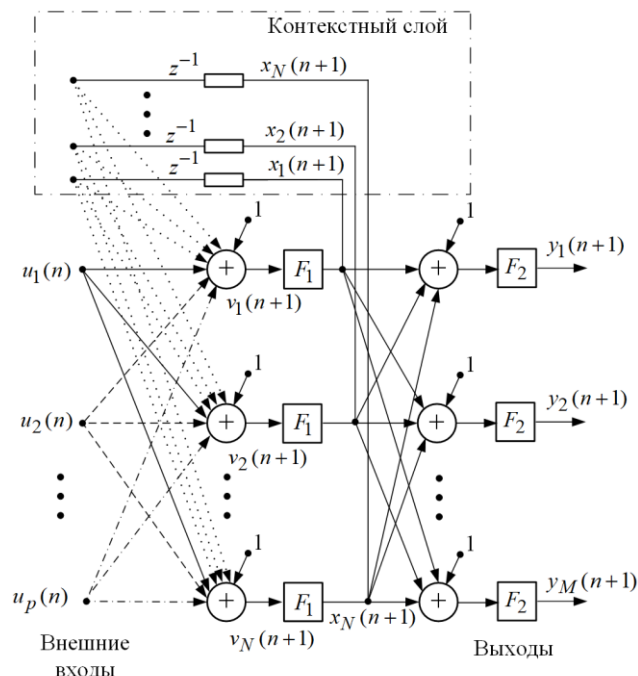


Рис. 2. Структура сети Элмана

Сеть Джордана успешно применяется для распознавания, различения и классификации временных последовательностей [1].

Структура сети Джордана представлена на рис. 3. Сеть Джордана – это многослойная персептронная сеть с одним скрытым слоем и контурами обратной связи между выходами и дополнительными входами сети, сформированными в контекстном слое. Контекстный слой содержит также повторные контуры обратной связи с коэффициентом ослабления памяти α , $0 \leq \alpha \leq 1$. В итоге, на выходе контекстного слоя присутствуют как текущие, так и взвешенные предыдущие сигналы обратной связи. Описанное свойство обеспечивает более «глубокую» память сети Джордана по сравнению с сетью Элмана.

Рекуррентная многослойная персептронная сеть (RMLPN) построена на основе однонаправленной многослойной персептронной сети путем добавления обратных связей между соседними нейронами внутри скрытых слоев, а также обратных связей нейронов на себя. Нелинейные свойства сети формируются в прямых связях, а динамические свойства – в обратных связях.

Сеть RMLPN успешно применяется для идентификации динамических систем [1]–[5].

Блок-схема RMLPN с двумя скрытыми слоями показана на рис. 4.

Недостатками RMLPN является повышенная сложность, зависящая от количества скрытых нейронов, и высокая длительность процесса обучения сети.

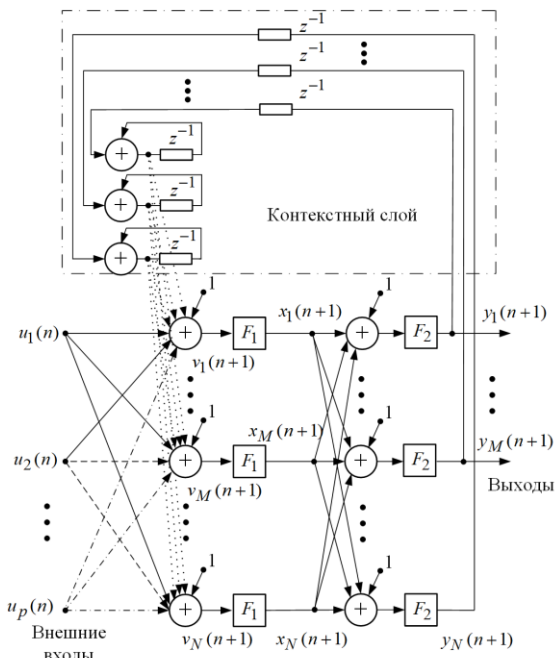


Рис. 3. Структура сети Джордана

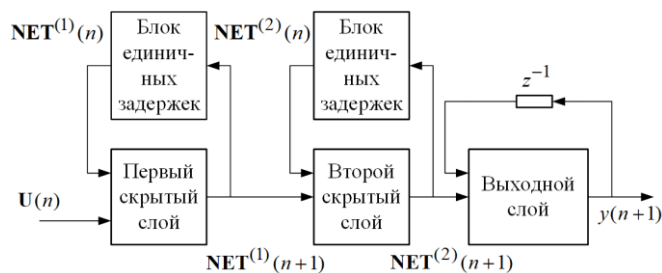


Рис. 4. Блок-схема RMLPN с двумя скрытыми слоями

С. Рекуррентные сети в пространстве состояний

Блок-схема рекуррентной сети в пространстве состояний показана на рис. 5. Выходные сигналы скрытого слоя (сигналы пространства состояний) проходят через блок единичных задержек и поступают на вход сети. Размерность пространства состояний задает порядок сети. Пользователь может выбрать количество нейронов скрытого слоя, формирующих сигналы для контура обратной связи.

Математическими моделями рекуррентных сетей в пространстве состояний являются системы нелинейных разностных (с дискретным временем) или дифференциальных (с непрерывным временем) уравнений состояния. Среди моделей данного типа можно выделить модели Хопфилда и Гроссберга, широко применяемые на практике [1], [2].

Рекуррентные сети в пространстве состояний обладают рядом преимуществ [1]:

- модели данных сетей описывают широкий класс нелинейных динамических систем;

- число состояний (порядок) сети не равно числу скрытых нейронов. Только те скрытые нейроны, выходные сигналы которых поступают в обратную связь, проходят через элементы задержки и приходят на вход, определяют состояния сети. Нейроны выходного слоя не влияют на пространство состояний;
- поскольку сигналы состояния поступают через обратную связь на вход сети, эти сигналы доступны для измерения или определения. Данное свойство полезно для нахождения начальных условий сети в разные моменты времени.

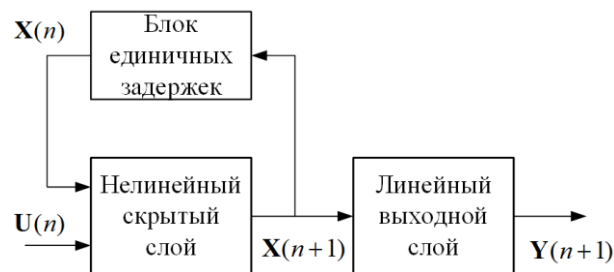


Рис. 5. Блок-схема рекуррентной сети в пространстве состояний

Несмотря на то, что рассматриваемые сети кажутся более перспективными по сравнению с полносвязными и частично рекуррентными сетями, их применение сталкивается со следующими трудностями [1]:

- построение математической модели в пространстве состояний возможно на компактных подмножествах сигналов и на конечных временных интервалах, в результате динамические характеристики сети не всегда описываются в полной мере;
- неточные начальные условия сети замедляют ее обучение, особенно при коротких последовательностях входных и выходных сигналов;
- возможно появление неустойчивости сети в процессе ее обучения.

Отмеченные недостатки ярко проявляются в тех случаях, когда начальные условия не известны и их невозможно оценить.

Д. Клеточные нейронные сети

Клеточная нейронная сеть (cellular neural network, CNN) – это объединение локально связанных клеток (нейронов), где каждая клетка – нелинейная динамическая система со входом, выходом и некоторым состоянием, описываемым динамическим уравнением. Каждая клетка взаимодействует непосредственно с соседними клетками. Взаимодействие клеток, не являющихся соседними, возникает из-за эффекта распространения динамики в сети [6]–[8].

CNN с локально связанными клетками производит параллельную обработку сигналов. Данное свойство

отличает CNN от других сетей и является преимуществом, позволяющим чрезвычайно быстро выполнять сложные преобразования одномерных и многомерных сигналов в телевидении, робототехнике, дистанционном управлении, нейрофизиологии.

CNN-модели разнообразны. Они различаются параметрическим и динамическим описаниями клеток, а также топологиями сетей [6]–[8].

Рассмотрим стандартную двумерную (two-dimensional) CNN в непрерывном времени. Клетку, расположенную на позиции (i, j) в двумерной области с размером $M \times N$, обозначим C_{ij} . Окрестность клетки N_{ij}^r , где r – размер окрестности (положительное целое число), формируется согласно выражению

$$N_{ij}^r = \{ C_{kl} \text{ при } \max(|k-i|, |l-j|) \leq r, 1 \leq k \leq M; 1 \leq l \leq N \}.$$

Нелинейный динамический процесс в клетке C_{ij} описывается двумя уравнениями (дифференциальным уравнением первого порядка и нелинейным уравнением на выходе клетки):

$$\frac{dx_{ij}(t)}{dt} = -\gamma x_{ij}(t) + \sum_{kl \in N_{ij}^r} \mathbf{A}_{ij,kl} y_{kl}(t) + \sum_{kl \in N_{ij}^r} \mathbf{B}_{ij,kl} u_{kl}(t) + I_{ij}$$

$$y_{ij}(t) = F(x_{ij}(t)),$$

где $x_{ij}(t)$, $u_{ij}(t)$, $y_{ij}(t)$ – переменная состояния, входной и выходной сигналы клетки соответственно; γ – константа; I_{ij} – постоянная смещения клетки; $\mathbf{A}_{ij,kl}$ – матрица трафарета обратной связи; $\mathbf{B}_{ij,kl}$ – матрица трафарета прямой связи (входного трафарета или трафарета управления); F – нелинейная функция.

Структура клетки изображена на рис. 6, где \int – операция интегрирования.

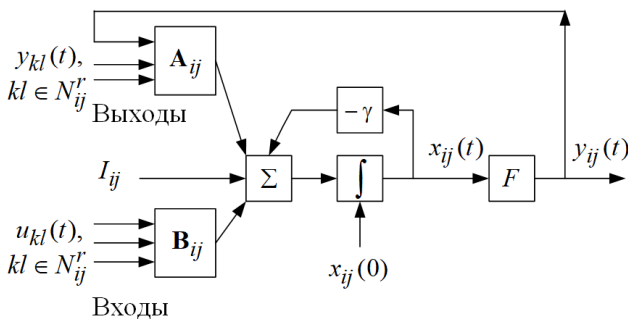


Рис. 6. Структура клетки в CNN

CNN широко применяются для линейной и нелинейной фильтраций, выделения различных свойств изображений, генерирования нелинейных колебаний и хаотических процессов, распознавания образов и решения нелинейных частных дифференциальных уравнений. На основе аналоговых и дискретных сетей разработана CNN-технология (высоко интегрированные чипы) и создана сотовая архитектура компьютера [6]–[8].

III. ЗАКЛЮЧЕНИЕ

Математическое моделирование нелинейных динамических систем рассматривается как задача установления соотношения вход/выход систем с применением нейронных сетей, в частности, рекуррентных сетей. В зависимости от расположения обратных связей сети разделены на глобально и локально рекуррентные. Внутри глобально рекуррентных нейронных сетей выделены и описаны разные типы структур с обратными связями между нейронами.

Приведенный анализ полезен для выбора структуры нейронной сети априори (до ее обучения, т.е. до построения математической модели нелинейной системы). Данный аспект важен, поскольку задача моделирования нелинейных систем в общей постановке сложна, поэтому целесообразно априори выбрать конструктивную модель, обеспечивающую высокую точность аппроксимации соответствия вход/выход нелинейной динамической системы.

СПИСОК ЛИТЕРАТУРЫ

- [1] Haykin S. Neural networks and learning machines. New York: Pearson Education Inc., 2009.
- [2] Patan K. Artificial neural networks for the modelling and fault diagnosis of technical processes. Berlin: Springer-Verlag Berlin Heidelberg, 2008.
- [3] Tang H., Tan K. C., Yi Z. Neural networks: computational models and applications. Berlin: Springer-Verlag Berlin Heidelberg, 2007.
- [4] Bianchini M., Maggini M., Jain L.C. Handbook on neural information processing. Berlin: Springer-Verlag Berlin Heidelberg 2013.
- [5] Speech, audio, image and biomedical signal processing using neural networks / Ed.: B. Prasad, S.R. Mahadeva Prasanna. Berlin: Springer-Verlag Berlin Heidelberg, 2008.
- [6] Yalcin M.E., Suykens J.A.K., Vandewalle J.P.L. Cellular neural networks, multi-scroll chaos and synchronization. Singapore: World Scientific Publishing Co. Pte. Ltd., 2005.
- [7] Chaos, CNN, memristors and beyond. A festschrift for Leon Chua. / Ed. A. Adamatzky, G. Chen. New York: World Scientific Publishing Co. Pte. Ltd., 2013.
- [8] Behavioral models of nonlinear filters based on discrete time cellular neural networks / Solovyeva E. // Vibroengineering Procedia. Proceedings of the 26th International Conference on Vibroengineering, Russia, St. Petersburg, June 29-30, 2017 / Saint-Petersburg Electrotechnical University "LETI", St. Petersburg, 2017. Vol. 12, June. P. 130–134.