

Моделирование распределенной памяти, обучения и распознавания образов в случайных нейросетевых структурах

Д. О. Жуков¹, Е. Г. Андрианова², Л. А. Истратов³

Московский технологический университет (МИРЭА)

¹zhukovdm@yandex.ru, ²dtghmflys@gmail.com, ³kuyahstibov@gmail.com

Аннотация. В представленной работе обсуждаются вопросы моделирования распределенной памяти, обучения и распознавания образов в нейросетевых структурах, имеющих случайное строение. На основании этого, авторы представляют в статье новую архитектуру нейронных сетей и описывают их функционирование и свойства. В статье предложена структура реализации памяти случайной нейронной сети, модель её обучения и механизм распознавания образов. Предложенная модель сети показывает возможность параллельно обрабатывать большое число вводимых образов и обладает пластичностью при одновременной стабильности.

Ключевые слова: нейронная сеть; моделирование распределенной памяти; случайные структуры; механизм распознавания образов

I. ВВЕДЕНИЕ

Применение технологий искусственного интеллекта в различных областях имеет всеобъемлющий характер и по интенсивности развития близко к информационному взрыву, что в значительной степени связано с достигнутыми в последние десятилетия успехами по созданию новых моделей нейронных сетей. Однако следует отметить, что большая часть исследований в области нейросетевых технологий в основном направлена на совершенствование имеющихся методов и их применение в прикладных задачах (99,9 %), что является актуальным, но не приводит к появлению существенно новых моделей, которые можно было бы назвать ANN 2.0 (Искусственные Нейронные Сети 2.0). Поэтому, на наш взгляд, моделирование памяти, обучения и механизмов распознавания образов в случайных нейросетевых структурах, структурно схожих с биологическими сетями, является важной и актуальной задачей, решение которой может приблизить нас к появлению технологий ANN 2.0.

II. ОБЗОР НЕКОТОРЫХ НЕЙРОСЕТЕВЫХ МОДЕЛЕЙ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА

Можно перечислить целый ряд проблем, существующих в современных нейросетевых технологиях, и требующих для решения создания новых моделей. В частности, например, использование большого числа входов для обучения искусственных нейронных сетей (ANN) в прикладных задачах требует значительного

объема данных для эффективной оценки веса соединений, а также увеличивает время обучения и риск того, что алгоритм обучения застрянет в локальном минимуме. В работе [1], для решения этих проблем представлен обзор современных исследований, посвященный созданию эффективных методов обучения искусственных нейронных сетей, в частности, например, на основе использования генетических алгоритмов.

Другим примером дальнейшего развития нейросетевых технологий могут служить комплексные нейронные сети. Описанию архитектуры и использованию которых посвящен ряд обзоров [2, 3].

Отметим, что ограничения имеющихся нейросетевых технологий способствуют не только улучшению существующих подходов, но и поиску новых направлений развития в области искусственного интеллекта. В частности, в настоящее время идет разработка нейронных сетей так называемого третьего поколения [4], получивших название Spiking Neuron Networks (SNN). Описанию которых и применению посвящен обзор [5].

Кроме того, следует отметить, что имеются и весьма экзотические подходы к созданию моделей искусственных нейронных сетей. В работе [6] предлагается оригинальная модель нелинейной нейронной сети на основе механизма самообновления памяти, который может быть описан в терминах теории катастроф, как странный аттрактор.

III. ПРЕДЛАГАЕМАЯ ТОПОЛОГИЧЕСКАЯ СТРУКТУРА ПАМЯТИ НЕЙРОННОЙ СЕТИ И МОДЕЛЬ ЕЁ ОБУЧЕНИЯ

Основываясь на биологическом строении коры головного мозга и его функционировании [7], можно говорить о том, что на физическом уровне нейросетевая память может быть образована из множества тормозящих и возбуждающих нейронов, иерархически связанных между собой как по вертикали, так и по горизонтали (рис. 1) в вертикальные и горизонтальные условные плоскости.

Перекрывающиеся области конкуренции близких нейронов смежного слоя должны (в соответствии с реальной биологической структурой мозга) содержать относительно небольшое число других нейронов, поэтому конкретный нейрон – победитель не может осуществить

торможение всего смежного слоя (рис. 2). В конкурентной борьбе будут выигрывать только несколько нейронов смежного слоя. На рис. 1 и 2 показано, что области связи соседних узлов значительно перекрываются. Такое дублирование функций необходимо для взаимной конкуренции между ближайшими узлами, а кроме того это соответствует структуре реальных биологических сетей.




Рис. 1. Физическая структура нейросетевой памяти

Синаптические веса тормозящих узлов, в сети представленной на рис. 1 (как и в случае, например когнитрона), не изменяются в процессе обучения; их веса заранее установлены таким образом, что сумма весов в любом из тормозящих нейронов равна единице.




Рис. 2. Структура связей нейронов между слоями

Процедура обучения. Веса возбуждающих нейронов изменяются только тогда, когда нейрон возбужден сильнее, чем любой из узлов в области конкуренции. В процессе обучения веса каждого узла в постсинаптическом слое (слой 2) настраиваются таким образом, что вместе они составляют шаблон, соответствующий образам, которые часто предъявляются в процессе обучения. При предъявлении сходного образа шаблон соответствует ему, и узел вырабатывает большой выходной сигнал. Сильно отличающийся образ вызывает малый выход и подавляется конкуренцией.

Работа сети должна быть с одной стороны обеспечивать пластичность памяти, а с другой стороны стабильность. Рассмотрим, каким образом это может быть реализовано структурой, изображенной на рис. 1.

Получая обучающий набор входных образов от точки входа А (рис. 1), сеть посредством изменения силы синаптических связей может в конечном итоге так самоорганизоваться, что при распознавании входных образов будет самонастраиваться.

При обучении в заданной области каждого слоя должны обучаться только наиболее сильно возбужденные нейроны, которые уже хорошо обучены, что должно выражаться силой их возбуждения, т.е. они должны получать приращение силы своих синапсов с целью дальнейшего усиления своего возбуждения. При этом при предъявлении первого обучающего образа в сети, представленной на рис. 1, должна образовываться цепочка, состоящая из связанных между собой сильно возбужденных нейронов (рис. 3 а), и проходящая через все слои от точки входа А до точки выхода В на рис. 1.




Рис. 3. Образование и усложнение строения структур нейронов при обучении

При представлении следующего обучающего образа может происходить как увеличение силы возбуждения возбужденных нейронов в образовавшейся цепочке и увеличение силы их синаптических связей, так и подключение к уже существующей цепочке новых сильно возбужденных нейронов (рис. 3в и 3с). При предъявлении всех последующих обучающих образов этот процесс будет продолжаться и в конечном итоге может привести к образованию достаточно сложной структуры, представленной на рис. 3с. Заметим, что в процессе обучения какие – то из нейронов могут и исключаться из цепочек или структур, показанных на рис. 3в и 3с.

Структуру (рис. 3с), образовавшуюся после обучения, в сети, показанной на рис. 1 можно изобразить в виде криволинейной трубки (рис. 4). Данная трубка будет иметь

область входа, связанную с точкой входа А (левый конец) и область выхода (правый конец) связанную с точкой выхода В.

При предъявлении нового образа могут происходить следующие процессы. Если возникающая цепочка сильновозбужденных нейронов любым возможным способом проходит от входа до выхода внутри любой из ранее сформировавшихся (при различных наборах обучающих образов) криволинейных трубок, то данный образец идентифицируется, как принадлежащий представляемому при обучении объекту (возникает резонанс или проводимость).




Рис. 4. Графическое представление криволинейной трубки памяти, образующейся при обучении

Следует отметить, что при обучении на выборке образов должен реализовываться механизм ограничения взаимодействия между тормозящими и возбуждающими нейронами, чтобы диаметр (измеряется в числе нейронов) криволинейной трубки обучения в каждом из слоев не мог бесконечно увеличиваться, а достигал бы некоторой конечной величины. Таким образом, формирование криволинейных трубок обучения конечного небольшого диаметра будет обеспечивать стабильность работы (не разрушать память о старых образцах). При удачном поиске в памяти предъявленный образ будет классифицироваться с одновременной уточняющей модификацией синаптических весов (возникновение адаптивного резонанса в сети в ответ на предъявление образа, как это происходит в сетях адаптивного резонанса АТР).

Если цепочка, возникающих при предъявлении образа сильновозбужденных нейронов, не проходит, или только частично проходит через ранее сформировавшиеся криволинейные трубки, то в сети, представленной на рис. 1, то в соответствии с моделью, представленной на рис. 3 начинается формирование новой трубки. В данном случае происходит адаптация к новой информации (пластичность памяти).

После обучения на множестве обучающих выборок различных образов объектов возможно образование сложных распознающих структур (автомат распознавания, который может включать пересекающиеся трубки) или подсетей, имеющий вид, представленный на рис. 5. Криволинейные трубки памяти (М-1) и М частично совпадают (в слоях IV и V) см. рис. 5, но при этом будут распознавать различные классы образов.




Рис. 5. Графическое представление распознающих структур

При значительном совпадении криволинейных трубок памяти, возбуждение цепочки нейронов при распознавании образов в одной из них (возникновение резонанса), будет приводить к возбуждению цепочки нейронов в другой. Возможно, именно такой механизм восприятия информации иногда возникает в реальных биологических структурах, когда одни образы вызывают рождение иных образов. Предложенная модель, за счет наличия множества криволинейных трубок обучения, обладает способностью параллельным образом обрабатывать одновременно сразу большое число вводимых образов объектов, обладает пластичностью при одновременной стабильности, и имеет распределенный характер памяти.

IV. ПРЕДЛАГАЕМАЯ ПЕРКОЛЯЦИОННАЯ МОДЕЛЬ РАСПОЗНАВАНИЯ ОБРАЗОВ

Распознавание образов может происходить следующим образом. На вход может одновременно подаваться множество образов, для некоторых из которых могут быть записанные следы памяти (нейроны, хранящие определенные концентрации нейропептидов и соединенные между собой в показанные на рис. 5 распознающие структуры). Нейроны, в которых есть соответствующая для данного образа концентрация вещества памяти будут являться проводящими узлами распознающей сетевой структуры (способны

возбуждаться), а в которых нет – блокирующими (тормозящими). При подаче на вход множества образов, в каких-то из распознающих структур могут возникнуть цепочки возбужденных узлов, а в каких-то, нет. Проводящие узлы могут возбуждаться, а связанные с ними блокирующие узлы могут оказывать тормозящее воздействие и гасить их возбуждение (переводить в заблокированное состояние). При возникновении проводимости (возбуждения) в целом во всей распознающей структуре она идентифицирует хранящейся в ней объект, в противном случае он оказывается не классифицированным.

Процесс распознавания образов можно рассмотреть с позиций теории перколяции и достижения в сети порога протекания (перколяции) – минимальной доли проводящих узлов сети, при котором в ней (в целом) появляется проводимость.

Проведенное численное моделирование [8, 9] зависимости порогов перколяции от плотности сетей (среднего числа связей, приходящихся на один узел) показывает, что полученные данные для задачи возбуждения узлов линеаризуются (со значением коэффициента корреляции, равным 0,95) в координатах: натуральный логарифм порога перколяции ($y = \ln P$) – величина (z) обратная плотности сети x ($z = 1/x$). Используя полученное в работах [8, 9] уравнение: $y = 4,39z - 2,41$ и учитывая, что каждый нейрон может иметь от 10 до 1000 связей с другими, то для порогов перколяции можно получить следующие оценки: 0,14 для среднего числа связей 10 и 0,10 для 100.

Если определить функцию сети, как величину порога перколяции (возникновения проводимости), то распознавание будет зависеть от плотности связей.

Теория перколяции позволяет объяснить возникновения механизма очень быстрого распознавания образов мозгом человека. Исследования в области нейрофизиологии показали, что минимальное время распознавания графических объектов составляет 0,013 с [10], что примерно равно времени одного переключения, равного 0,010 с. В самом быстром случае, распознавание происходит без переключения в нейронной сети за счет мгновенного срабатывания одной из распознающих структур, в которой при предъявлении образа сразу возникла проводимость.

V. ЗАКЛЮЧЕНИЕ

Анализ предметной области показывает, что в используемых искусственных нейронных сетях имеется ряд недостатков, без преодоления которых не могут быть созданы технологии ANN 2.0. Требуется поиск новых моделей, более приближенных к структуре и функциональным свойствам биологических нейронных сетей.

Для создания моделей нейронных сетей нового поколения, необходимо учитывать структуру и механизм

функционирования реальных биологических объектов. В частности то, что память имеет распределенный характер, а мозг способен одновременно распознавать большое число образов (обладает высоким параллелизмом).

Предлагаемая модель памяти обладает пластичностью при одновременной стабильности и позволяет параллельно обрабатывать большое число вводимых образов. Кроме того, она может быть лишена недостатков, присущих когнитрону, неокогнитрону и сетям адаптивного резонанса (АТР), например, имеет в отличие от них распределенный характер памяти.

Механизм распознавания образов в предлагаемой модели может быть описан в терминах теории перколяции для сетей, имеющих случайную структуру. В частности, в качестве функции активации можно использовать величины порогов перколяции (протекания) сетей, которые зависят от их плотности.

Полученные результаты можно использовать на практике для создания моделей нового поколения нейросетевых технологий. Однако для этого требуется разработать ещё конкретные алгоритмы работы описанной модели, её обучения и распознавания образов.

СПИСОК ЛИТЕРАТУРЫ

- [1] da Costa Couto M.P. Review of input determination techniques for neural network models based on mutual information and genetic algorithms. // *Neural Computing and Applications*. 2009. Vol. 18, Issue 8, P. 891-901.
- [2] Models of orthogonal type complex-valued dynamic associative memories and their performance comparison. Kuroe Y., Taniguchi Y. / *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, Volume 4668 LNCS, Issue PART 1, 2007. P. 838-847.
- [3] Complex Valued Neural Networks: Models and algorithms. / Zouhour B.S.N. // *Proceedings of the 2009 International Conference on Artificial Intelligence, ICAI 2009*, Volume 1, 2009. P. 39-42.
- [4] Maass Wolfgang. Networks of spiking neurons: The third generation of neural network models. // *Neural Networks*. 1997 No. 10 (9). P. 1659–1671.
- [5] Ahmed F.Y.H., Yusob B., Hamed H.N.A. Computing with spiking neuron networks a review. // *International Journal of Advances in Soft Computing and its Applications*. 2014. Volume 6, Issue 1, P. 156 – 167.
- [6] Musca S.C., Rousset S., Ans, B. Artificial neural networks whispering to the brain: Nonlinear system attractors induce familiarity with never seen items. // *Connection Science*. 2009. Vol. 21, Issue 4, P. 359-377.
- [7] Устройство памяти. От молекул к сознанию. С. Поуз. / Пер. с англ. М.: Мир, 1995. 384 с.
- [8] Zhukov Dmitry, Khvatova Tatiana, Lesko Sergey, Zaltsman Anastasia. Managing social networks: applying the Percolation theory methodology to understand individuals' attitudes and moods. // *Technological Forecasting and Social Change*. 2017, Vol. 123, P. 234–245.
- [9] Percolation models of information dissemination in social networks. / S.A. Lesko, D.O. Zhukov. // *Proceedings of the 8th IEEE International Conference on Social Computing and Networking, SocialCom 2015 / 19 -21 December, 2015, Chengdu, Sichuan, China*. P. 213 – 216.
- [10] Potter Mary C., Wyble Brad, Hagmann Carl Erick, McCourt Emily S.. Detecting meaning in RSVP at 13 ms per picture. // *Attention, Perception, & Psychophysics*. 2014, Vol. 76, Issue 2, P. 270–279.