

# Нейронные сети для классификации ЭЭГ: от перцептрона до сверточной LSTM-сети

М. И. Ямаев<sup>1</sup>, С. П. Шипицин<sup>2</sup>

Пермский национальный исследовательский  
политехнический университет

<sup>1</sup>viziter@live.com, <sup>2</sup>shipitsin.sp@yandex.ru

Е. С. Филатова

Санкт-Петербургский государственный  
электротехнический университет  
«ЛЭТИ» им. В.И. Ульянова (Ленина)

**Аннотация.** В данной статье описывается процесс эволюции классификаторов сигналов ЭЭГ для интерфейса «мозг-компьютер». Обсуждаются преимущества и недостатки предварительной фильтрации и выделения признаков ЭЭГ перед классификацией. Прослеживается постепенное смещение внимания исследователей на нейросетевые подходы, которые долгое время были не актуальны в силу низкой эффективности в прикладных задачах. Рассматривается ряд нейросетевых классификаторов: перцептроны, сверточные нейронные сети, рекуррентные нейронные сети и другие. В результате проведенного анализа определяется область дальнейших исследований в области классификации сигналов ЭЭГ.

**Ключевые слова:** интерфейс мозг-компьютер; классификация; нейронные сети; электроэнцефалограмма

## I. ВВЕДЕНИЕ

Классификация ЭЭГ паттернов – одна из ключевых проблем для интерфейсов «мозг-компьютер» (ИМК). Вопрос классификации является открытым, потому что до сих пор решаются проблемы точности и оптимизации этих интерфейсов. Причём чем больше успехов исследователей в анализе данных, тем лучше продвигается технология. Для поощрения и объединения исследователей проводятся различные конкурсы на лучшую реализацию или применение, например BCI Award последних нескольких лет или BCI Competition I-IV. В 2016 г. прошёл Cybathlon, который был первым международным соревнованием людей с ограниченными возможностями, использующих высокотехнологичные ассистивные устройства [1], в том числе ИМК. Сегодня данная технология широко используется в робототехнике и нейропротезировании [2]. К тому же ИМК можно использовать в развлекательной индустрии и бытовой сфере человека.

Считываемый с помощью ИМК сигнал электроэнцефалограммы (ЭЭГ) нуждается в предварительной обработке, так как изначально сигнал очень сильно зашумлён. В процессе предобработки сигнал сначала очищается от шума, после чего из него выделяют необходимые признаки [3], которые затем классифицируют. Классификаторы нередко основаны на методах машинного обучения, к которым относятся нейросети. Они отлично себя зарекомендовали для

решения таких задач. В статье обсуждаются значимые нейросетевые подходы применительно к обработке ЭЭГ для ИМК, а также их развитие со временем.

## II. ЭВОЛЮЦИЯ КЛАССИФИКАТОРОВ ЭЭГ

До конца 80-х годов XX века нейронные сети почти не использовались в практических приложениях, но с появлением алгоритма обратного распространения ошибки, позволяющего обучать такие сети, ситуация в корне поменялась. Впрочем, оптимизм исследователей был недолгим – скорость обучения сети оставалась крайне низкой, прежде всего из-за проблемы исчезающих градиентов. По этой причине нейронные сети в 1990-х гг. уступили место методу опорных векторов (англ. support vector machine, SVM). Этот линейный классификатор тогда использовался для многих типов задач [4, 5] и до сих пор иногда встречается в составе более сложных систем. В целом разнообразных классификаторов, менее популярных и не таких известных, масса: линейный дискриминантный анализ; наивный байесовский классификатор; двоичное дерево принятия решений [6] и другие. До середины 2000-х простые классификаторы превалировали, однако с ростом вычислительных мощностей постепенно отошли на второй план, а нейронные сети сейчас переживают очередной расцвет.

Зачастую первые применения ИМК были медицинскими. К примеру, распознавание эпилептических приступов. После начали выделять одно-классовую и много-классовую задачи. К их числу относится распознавание движений и их воображений.

## III. ПЕРЦЕПТРОНЫ

Очевидно, среди первых нейросетевых классификаторов был перцептрон, точнее, многослойный перцептрон (англ. multilayer perceptron neural network, MPLNN). На вход сети напрямую поступали либо единичные паттерны временного ряда, либо вектора из нескольких паттернов. Топология многослойного перцептрона показана на рис. 1. Низкая эффективность перцептрона в чистом виде обусловила необходимость введения дополнительной обработки данных. Сигнал либо




Рис. 1. Топология многослойного перцептрона

подвергался предварительной фильтрации для выделения признаков [7], либо фильтрации непосредственно внутри сети [8]. Одиночно MPLNN для классификации движений сейчас не используется, его применяют вместе с другими видами нейронных сетей.

#### IV. СВЕРТОЧНЫЕ НЕЙРОННЫЕ СЕТИ

На основе модели зрительной системы Кунихио Фукусима предложил когнитрон и неокогнитрон [9], которые впоследствии стали сверточными нейронными сетями (англ. convolutional neural network, CNN) благодаря Яну ЛеКунну. Из-за того, что структура сети опирается на систему зрительной коры, в решении задач классификации изображений такая сеть показывает себя наилучшим образом. Топология CNN показана на рис. 2. Например, распознавание рукописных букв. Когда дело касается сигнала ЭЭГ формируются матрица вида  $N \times T$ , где  $N$  число каналов ИМК, а  $T$  это число взятых для анализа отсчетов. Сверточная нейронная сеть показала себя лучше, чем MPLNN и SVM, в том числе для многоклассовой задачи [10]. С появлением глубоких нейронных сетей начали появляться подходы, не требующие предварительного выделения признаков. К примеру в [11] предложен подход, где с помощью CNN распознаётся чистый сигнал. Кроме того CNN очень хорошо себя показала при анализе в частотной области сигнала ЭЭГ [12]. Авторы показали, что CNN в данной задаче превзошли MPLNN и рекуррентные нейронные сети.




Рис. 2. Топология сверточной нейронной сети

#### V. ГЛУБОКИЕ СЕТИ ДОВЕРИЯ

Глубокие сети доверия (англ. Deep belief network, DBN) представляют собой развитие идей стохастических (вероятностных) сетей. Глубокими эти сети называются потому, что представляют собой композицию (обычно каскад) простых сетей наподобие ограниченных машин Больцмана или автокодировщиков. Такая архитектура стала логическим следствием борьбы с недостатками простых стохастических сетей, которые в чистом виде относительно плохо справляются с задачами классификации. Как и прочие глубокие нейросетевые архитектуры, DBN долгое время применялись очень ограниченно в связи с чрезвычайно сложным процессом обучения, но с появлением действенных алгоритмов глубокого обучения, начиная с 2006 [13], вызывают большой интерес исследователей в том числе в области распознавания ЭЭГ.

##### А. Ограниченные машины Больцмана

Машина Больцмана является генеративной стохастической нейронной сетью и представляет собой стохастический вариант сети Хопфилда. Первая нейронная сеть, позже получившая название ограниченной машины Больцмана (англ. Restricted Boltzmann machine, RBM), была построена в 1986 году Полом Смоленски. Своё название эта архитектура получила как модификация машины Больцмана, в которой нейроны разделили на видимые и скрытые. Связи допустимы только между нейронами разного типа, что позволило существенно снизить количество связей и ускорить процесс обучения, используя, например, метод градиентного спуска. Топология RBM показана на рис. 3. Применение этих сетей целесообразно показать в контексте DBN. В статье [14] демонстрируется существенно более высокая скорость работы глубокой сети RBM по сравнению с SVM при незначительном снижении качества распознавания. Несколько позднее, в [15], авторы смогли уже по всем параметрам превзойти SVM.

##### В. Автокодировщики

Автокодировщик или автоэнкодер (англ. autoencoder) представляет собой нейросетевую архитектуру, напоминающую по строению перцептрон и специально предназначенную для получения на выходе сети наиболее точной аппроксимации входной функции. Отличие состоит в ограничениях, которые накладываются



Рис. 3. Топология ограниченной машины Больцмана




Рис. 4. Топология автокодировщика

на промежуточный слой – он должен быть или меньшей размерности, чем входной и выходной, или активироваться частично. Топология изображена на рис. 4. Такой подход позволяет выполнять, с одной стороны, сжатие проходящих через сеть данных, с другой, искать в них обобщения и корреляции. Для распознавания ЭЭГ они также применяются в основном в составе DBN [16], но и в чистом виде как часть более сложной системы также встречаются [17].

## VI. РЕКУРРЕНТНЫЕ НЕЙРОННЫЕ СЕТИ

Главным отличием рекуррентных нейронных сетей (англ. Recurrent neural network, RNN) является наличие направленных связей между нейронами. Топология RNN показана на рис. 5. Это, как правило, обратные связи, которые обуславливают формирование у сети своего рода памяти. Данная особенность позволяет RNN, в отличие от статических алгоритмов наподобие многослойного перцептрона, улавливать временную динамику, обладая, таким образом, куда более широкими возможностями по анализу сигнала во временной области.

Исследования о применении RNN как для разделения источников сигналов [18], так и для непосредственно классификации ЭЭГ [19, 20, 21] проводились с начала 90-х, вместе с общим прогрессом в развитии таких сетей. В статье [22] оценивается нейронная сеть Элмана, где используются показатели Ляпунова. Сети Хопфилда были обделены вниманием, и




Рис. 5. Топология рекуррентной нейронной сети

только в 2012 появилась статья [23], показывающая её применение для кластеризации воображения движения.

Несмотря на достаточно высокие достигнутые показатели, следует отметить, что во всех перечисленных статьях сигнал, подаваемый на вход сети, проходит предварительную обработку и фильтрацию.

## A. Сети долгой краткосрочной памяти

Особый интерес в части, касающейся RNN, представляют сети долгой краткосрочной памяти (англ. Long short-term memory, LSTM). В отличие от традиционных рекуррентных сетей, LSTM-сеть хорошо приспособлена к обучению классификации на временных рядах с неопределёнными лагами и продолжительностью. Предложенная ещё в 1997 году, эта архитектура долгое время оставалась невостребованной в области распознавания сигналов ЭЭГ. В некоторых исследованиях того времени она используется [24, 25], но результаты этих исследований отличаются от предыдущих незначительно.

Действительно большую популярность LSTM-сети приобрели в последние годы, и теперь используются в качестве фундаментального компонента ключевых продуктов ведущих технологических компаний мира. С 2014 г. исследования, предлагающие использовать LSTM в качестве классификатора для сигнала ЭЭГ, начинают появляться одно за другим, но теперь фокус внимания смещается на архитектуру, сочетающую достоинства как свёрточных, так и рекуррентных сетей – свёрточную сеть долгой краткосрочной памяти. Это пока просто определённым образом соединённые свёрточные и рекуррентные слои, но даже такой подход уже разительно отличается по качеству распознавания от всех предшествующих в лучшую сторону. В статьях [26, 27] описывается несколько различных производных топологий. При этом в условиях отсутствия какой-либо предобработки сигнала в [27] авторы получают впечатляюще высокие результаты (0,9828), хотя и оперируют весьма значительным объёмом тестовых данных для более качественного обучения сети.

## VII. ДАЛЬНЕЙШИЕ ИССЛЕДОВАНИЯ

Несмотря на значительные успехи в области распознавания сигналов ЭЭГ, достигнутые к сегодняшнему моменту, остаётся несколько серьёзных проблем, которые пока не решены. В частности, подавляющее большинство исследований, особенно последних лет, проводится на высокопроизводительном оборудовании и оперирует значительными объёмами тестовых данных, полученных с научных электроэнцефалографов с большим количеством каналов. Потребительские и значительная часть медицинских устройств обладают куда более скромными возможностями, следовательно, повышенными требованиями в части производительности алгоритмов распознавания сигнала. И если дальнейший рост производительности компьютерной техники позволит использовать в потребительских приложениях системы распознавания любой вычислительной сложности, то просто увеличить количество датчиков на ИМК достаточно сложно, а зачастую и вовсе невозможно.

С другой стороны, регулярно появляются новые перспективные модификации архитектур нейронных сетей, которые потенциально могут давать в задаче распознавания ЭЭГ лучшие результаты, чем предшествующие. В 2015 была опубликована статья [28], описывающая полноценную архитектуру свёрточной сети долгой краткосрочной памяти (Convolutional LSTM, ConvLSTM), что радикально отличается от простого совмещения свёрточных и рекуррентных сетей, показанного выше. На основе этой концептуальной статьи уже появляются практические приложения, но применительно к распознаванию ЭЭГ эта архитектура пока не использовалась. Учитывая высокие показатели, которые удалось достигнуть, используя совмещённые сети, представляется, что и эта архитектура покажет как минимум сопоставимые результаты.

Резюмируя сказанное выше, сейчас задача исследователей в значительной степени сводится к редуцированию программно-аппаратного комплекса, составляющего ИМК. При этом стопроцентное качество многоклассового распознавания пока не достигнуто даже на больших объёмах данных, что также оставляет простор для дальнейших изысканий в данной области.

#### СПИСОК ЛИТЕРАТУРЫ

- [1] Krishnaswamy K., Kuber R., Oates T. Developing a limb repositioning robotic interface for persons with severe physical disabilities // *Universal Access in the Information Society*. 2016. Т. 15. №. 4. С. 609-627.
- [2] Riener R. The Cyathlon promotes the development of assistive technology for people with physical disabilities // *Journal of neuroengineering and rehabilitation*. 2016. Т. 13. №. 1. С. 49.
- [3] Jain A.K., Duin R.P. W., Mao J. Statistical pattern recognition: A review // *IEEE Transactions on pattern analysis and machine intelligence*. 2000. Т. 22. №. 1. С. 4-37.
- [4] Bennett K.P., Campbell C. Support vector machines: hype or hallelujah? // *Acm Sigkdd Explorations Newsletter*. 2000. Т. 2. №. 2. С. 1-13.
- [5] Garrett D. et al. Comparison of linear, nonlinear, and feature selection methods for EEG signal classification // *IEEE Transactions on neural systems and rehabilitation engineering*. 2003. Т. 11. №. 2. С. 141-144.
- [6] Bozhkov L. et al. EEG-based subject independent affective computing models // *Procedia Computer Science*. 2015. Т. 53. С. 375-382.
- [7] Orhan U., Hekim M., Ozer M. EEG signals classification using the K-means clustering and a multilayer perceptron neural network model // *Expert Systems with Applications*. 2011. Т. 38. №. 10. С. 13475-13481.
- [8] Haselsteiner E., Pfurtscheller G. Using time-dependent neural networks for EEG classification // *IEEE transactions on rehabilitation engineering*. 2000. Т. 8. №. 4. С. 457-463.
- [9] Fukushima K., Miyake S. Neocognitron: A self-organizing neural network model for a mechanism of visual pattern recognition // *Competition and cooperation in neural nets*. Springer, Berlin, Heidelberg, 1982. С. 267-285.
- [10] Sakhari S., Guan C., Yan S. Parallel convolutional-linear neural network for motor imagery classification // *Signal Processing Conference (EUSIPCO), 2015 23rd European*. IEEE, 2015. С. 2736-2740.
- [11] Nurse E. et al. Decoding EEG and LFP signals using deep learning: heading TrueNorth // *Proceedings of the ACM International Conference on Computing Frontiers*. ACM, 2016. С. 259-266.
- [12] Chu L. et al. Individual Recognition in Schizophrenia using Deep Learning Methods with Random Forest and Voting Classifiers: Insights from Resting State EEG Streams // *arXiv preprint arXiv:1707.03467*. 2017.
- [13] Bengio Y. et al. Learning deep architectures for AI // *Foundations and trends® in Machine Learning*. 2009. Т. 2. №. 1. С. 1-127.
- [14] Wulsin D.F. et al. Modeling electroencephalography waveforms with semi-supervised deep belief nets: fast classification and anomaly measurement // *Journal of neural engineering*. 2011. Т. 8. №. 3. С. 036015.
- [15] An X. et al. A deep learning method for classification of EEG data based on motor imagery // *International Conference on Intelligent Computing*. – Springer, Cham, 2014. – С. 203-210.
- [16] Narejo S., Pasero E., Kulsoom F. EEG Based Eye State Classification using Deep Belief Network and Stacked AutoEncoder // *International Journal of Electrical and Computer Engineering*. 2016. Т. 6. №. 6. С. 3131.
- [17] Li J. et al. Feature learning from incomplete EEG with denoising autoencoder // *Neurocomputing*. 2015. Т. 165. С. 23-31.
- [18] Amari S., Cichocki A., Yang H.H. Recurrent neural networks for blind separation of sources // *Proc. Int. Symp. NOLTA*. 1995. С. 37-42.
- [19] Petrosian A. et al. Recurrent neural network based prediction of epileptic seizures in intra-and extracranial EEG // *Neurocomputing*. 2000. Т. 30. №. 1-4. С. 201-218.
- [20] Petrosian A. A. et al. Recurrent neural network-based approach for early recognition of Alzheimer's disease in EEG // *Clinical Neurophysiology*. 2001. Т. 112. №. 8. С. 1378-1387.
- [21] Gotman J., Gloor P. Automatic recognition and quantification of interictal epileptic activity in the human scalp EEG // *Electroencephalography and clinical neurophysiology*. 1976. Т. 41. №. 5. С. 513-529.
- [22] Güler N.F., Übeyli E.D., Güler I. Recurrent neural networks employing Lyapunov exponents for EEG signals classification // *Expert systems with applications*. 2005. Т. 29. №. 3. С. 506-514.
- [23] Hsu W.Y. Fuzzy Hopfield neural network clustering for single-trial motor imagery EEG classification // *Expert systems with applications*. 2012. Т. 39. №. 1. С. 1055-1061.
- [24] Davidson P.R., Jones R.D., Peiris M.T. R. Detecting behavioral microsleeps using EEG and LSTM recurrent neural networks // *Engineering in Medicine and Biology Society, 2005. IEEE-EMBS 2005. 27th Annual International Conference of the IEEE*, 2006. С. 5754-5757.
- [25] Davidson P.R., Jones R.D., Peiris M.T.R. EEG-based lapse detection with high temporal resolution // *IEEE Transactions on Biomedical Engineering*. 2007. Т. 54. №. 5. С. 832-839.
- [26] Bashivan P. et al. Learning representations from EEG with deep recurrent-convolutional neural networks // *arXiv preprint arXiv:1511.06448*. 2015.
- [27] Zhang D. et al. EEG-based Intention Recognition from Spatio-Temporal Representations via Cascade and Parallel Convolutional Recurrent Neural Networks // *arXiv preprint arXiv:1708.06578*. 2017.
- [28] Xingjian S.H.I. et al. Convolutional LSTM network: A machine learning approach for precipitation nowcasting // *Advances in neural information processing systems*. 2015. С. 802-810.